

Trabajo Práctico N° 3

Perceptrón simple y multicapa

Detección de fraude y clasificación de dígitos para CompanyX

01

TinyModel para fraude

Perceptrón simple, destilación de conocimiento y decisión de umbral

El encargo: imitar a BigModel con diez parámetros

BigModel

probabilidad de fraude
entre 0 y 1

TinyModel

9 pesos + bias
una predicción muy barata

Knowledge distillation

El objetivo de entrenamiento es la salida continua de BigModel, no
flagged_fraud

Fraude: datos limpios, desbalanceados y con escalas muy distintas

7.500

transacciones

11,6 %

fraude real

9

entradas


0

faltantes o duplicados

- flagged_fraud no se usa para entrenar.
- Los candidatos IQR son observaciones plausibles: se conservan.
- La estandarización se ajusta sólo con los datos de training de cada protocolo.

Las entradas requieren una escala común

Desvío estándar en las unidades originales, expresado como log10



2,2 millones x

diferencia de desvío entre
timestamp y cantidad comprada

0

faltantes, infinitos
o duplicados exactos

Decisión

Estandarizamos las nueve entradas dentro de cada protocolo. Los candidatos IQR se conservaron porque podían ser transacciones válidas.

Comparación controlada: lineal frente a logístico

Lineal

$$\theta(h) = h$$

Puede devolver valores negativos o mayores que uno. No respeta el significado probabilístico.

Logístico

$$\theta(h) = 1 / (1 + e^{-2h})$$


La salida siempre pertenece a (0,1), igual que la probabilidad de BigModel.

Condiciones idénticas para aislar la activación

- Las 7.500 transacciones y las nueve entradas estandarizadas.
- MSE contra `big_model_fraud_probability`.
- Descenso básico, mini-batch 32 y 500 épocas.
- Mismos pesos iniciales, mezcla y semillas.
- $\eta \in \{0,0001; 0,001; 0,01; 0,1\}$.

Una sola variable experimental: la función de activación

$\eta = 0,01$ converge sin introducir oscilaciones



Ambos perceptrones saturan su capacidad

Modelo	Época 100	Época 500	Mejora
Lineal	0,026066	0,026080	ninguna
Logístico	0,010869	0,010868	0,000001

Más épocas no amplían lo que una frontera simple puede representar

Selección para generalización: perceptrón logístico

2,4x

menor MSE

100 %

salidas válidas


10

parámetros

La exponencial agrega un costo mínimo y evita probabilidades imposibles


El underfitting restante se acepta porque la consigna limita el ejercicio a perceptrones simples

Generalización: test reservado y 5-fold estratificado



La estandarización se recalcula dentro de cada fold

El error de validación es estable entre particiones



0,01102

MSE validation medio

$\pm 0,00056$

desvío entre folds

Dos objetivos requieren dos familias de métricas

Imitar a BigModel

MSE sobre datos no vistos

Mide cuánto se aleja TinyModel de la probabilidad continua que debe destilar.


Detectar fraude

Matriz de confusión, precision, recall, F1 y tasa de falsos positivos

Miden el impacto de aplicar un umbral.

Accuracy sola oculta el fracaso: predecir siempre “legítima” ya da 88,4 %


La validación confirma $\eta = 0,01$



η	MSE val.
0,001	0,01136
0,01	0,01102
0,1	0,01103

**0,01 empata en error,
pero termina casi sin
oscilación**

El umbral 0,89 maximiza F1 en validation




El umbral depende del costo de cada error

Umbral	Recall	Falsos positivos	Uso
0,80	95,1 %	4,2 %	Priorizar detección
0,89	85,9 %	1,5 %	Equilibrio por F1
0,95	74,5 %	0,5 %	Priorizar experiencia

Sin costos de negocio explícitos, F1 ofrece un compromiso defendible

En test, los errores se concentran cerca del límite



0,01053

MSE de test

44

errores sobre 1.500

**42 de 44 errores
ocurren con BigModel
entre 0,73 y 0,93**

Resultado final de TinyModel

97,1 %

accuracy

87,4 %

precision

87,4 %

recall

1,7 %

falsos positivos

152 / 174

fraudes detectados

22 / 1.326

clientes legítimos bloqueados

Conclusión del ejercicio 1

El perceptrón logístico es mejor que el lineal

- Respeta el rango probabilístico y reduce el MSE 2,4 veces frente al lineal.
- Generaliza de forma estable entre folds y semillas.
- El umbral 0,89 equilibra detección y falsas alarmas mientras no haya costos explícitos.
- TinyModel es más barato y explicable, pero conserva una brecha: difiere de BigModel en 44 de 1.500 decisiones.

Más barato y explicable, pero no equivalente a BigModel

02

Clasificación de dígitos

Perceptrón multicapa, búsqueda de hiperparámetros y una clase ausente

El problema: reconocer diez clases con development incompleto

12.449

imágenes de development

2.497

imágenes de test


784

píxeles por imagen

digits_test.csv simula producción y queda cerrado hasta congelar el modelo

Development sirve tanto para pesos como para hiperparámetros

El EDA anticipa el fallo principal



0

ejemplos del 8

271

ejemplos del 5

Evaluación: macro-F1 primero, accuracy como contexto

Selección

Macro-F1 sobre las clases presentes

F1 por dígito, con atención especial al 5
El 8 se evalúa únicamente en la evaluación final

MSE como señal de entrenamiento

Control

Holdout 80/20 estratificado para explorar

Cinco semillas para finalistas

5-fold para confirmar la decisión

El mejor checkpoint se elige con validation, nunca con test

Embudo experimental del ejercicio 2

1

Learning rate y batch

2

Ancho y profundidad

3

Optimizadores y cruces


4

Semillas y particiones

5

5-fold y modelo congelado

Las tasas intermedias convergen; los extremos fallan



APRENDIZAJE LENTO

$\eta = 0,001$ y $0,01$

Siguen mejorando al final de las 200 épocas.

ZONA COMPETITIVA

$\eta = 0,1$ a 3

Convergen rápido y alcanzan un Macro-F1 similar.


INESTABILIDAD

$\eta = 10$

No converge y queda cerca del desempeño aleatorio.

El barrido acota la búsqueda; luego ajustamos la tasa para cada optimizador.

Batch 128 y $\eta=2$ ofrecen el mejor compromiso



MEJOR MEDIA

Batch 64, $\eta=2$
Macro-F1 0,9259

MEJOR COMPROMISO


Batch 128, $\eta=2$
Macro-F1 0,9247 $\pm$ 0,0021
4,73 s · 23 % menos tiempo

DECISIÓN

Batch 128 y $\eta=2$ quedan como referencia para estudiar arquitectura.

La diferencia de Macro-F1 es menor que la variación entre semillas; elegimos estabilidad y costo.

Más capas ajustan mejor training, no validation



Batch 128, $\eta = 2$, descenso básico, 200 épocas, semilla 0. Mejor checkpoint de validation.

0,9307



validation con 1 capa

0,9276

mejor red de 2 capas

+8 % de parámetros sin mejora: se conserva la más simple

Cada optimizador requiere su propia tasa



TASAS SELECCIONADAS

GD: 2 Adaptativo: 1 RMSProp: 0,01


Adam: 0,001–0,01; luego 0,003 con 128 neuronas

DESCARTES

Momentum queda en un Macro-F1 menor.

GD $\eta=3$ es inestable; tasas altas de RMSProp y Adam colapsan.

Arquitectura y optimizador se ajustan en conjunto



FILTRO DE OPTIMIZADORES

Descartamos GD y Momentum. Continuamos con Adaptativo, RMSProp y Adam.

CRUCE CON ARQUITECTURA


Probamos distintas arquitecturas con las tasas seleccionadas para cada método.

DECISIÓN

64 y 128 neuronas quedan como finalistas para el ajuste local.


La arquitectura elegida depende del optimizador y de su learning rate.

RMSProp-64 ofrece el mejor equilibrio



RMSProp-64

estable · 7,3 s · 50.890 parámetros




Adam-128

media apenas mayor · 12,1 s · 101.770 parámetros

RMSProp-64 pasa a 5-fold como la alternativa eficiente frente a Adam-128.

68 épocas: el máximo medio de los cinco folds



68

épocas del modelo final

0,9479

macro-F1 medio en la
época 68

Configuración congelada antes de abrir test

Red

[784, 64, 10]

tanh en la capa oculta
logística en la salida
MSE


Entrenamiento

RMSProp, $\eta = 0,01$

batch 128
68 épocas
semilla 0

Se reentrena desde cero con las 12.449 imágenes de development

Producción expone la clase que nunca apareció en development



85,82 %

accuracy oficial

0 %

recall del 8

**Sin el 8, la accuracy
diagnóstica sería 95,08 %**

Conclusión del ejercicio 2

La optimización encuentra una red competitiva para los datos disponibles

- RMSProp-64 logra un desempeño comparable a Adam-128, con la mitad de parámetros y menor tiempo de entrenamiento.
- La profundidad adicional no mejora validation.
- La interacción arquitectura–optimizador importa tanto como cada elección aislada.
- El límite dominante en producción es la ausencia total del dígito 8.


Más neuronas no pueden reemplazar información que no existe

03

Nuevos datos, nuevo modelo

Softmax, entropía cruzada, augmentation y el objetivo de 98 %

Los datos nuevos corrigen cobertura, pero traen duplicados



15.741

filas nuevas

3.689

duplicados compartidos

24.501

imágenes únicas

El protocolo evita que test dirija la mejora


- **Baseline:** receta del ejercicio 2 aplicada sin cambios al development ampliado.
- **Un cambio por etapa y cinco semillas para cada candidato.**
- **Desde el schedule, comparación en la época 300, no por el mejor pico.**
- **Candidato final ya fijado: confirmación mediante 5-fold.**
- **Reentrenamiento con las 24.501 imágenes y evaluación única sobre test.**

Los duplicados se eliminan antes del split para evitar fuga entre training y validation.

La mejora surge de una secuencia de decisiones


Etapa	Accuracy val.	Lectura
Baseline MSE	95,90 %	las 5 semillas aprenden el 8
Softmax + CE	96,20 %	mejora en 5/5 semillas
Traslaciones	97,36 %	se conserva; L2 se retira
Schedule	97,33 %	época fija, -61 % fluctuación
96 neuronas	97,73 %	candidato final

Softmax y entropía cruzada: mejora chica pero consistente



- Softmax convierte las diez salidas en probabilidades que suman 1.
- Finalistas de una búsqueda entre 10^{-4} y 10^{-1}
- Con $\eta = 0,01$, el Macro-F1 promedio sube de 0,9459 a 0,9492; mejora en 4 de 5 semillas.



Las traslaciones mejoran el desempeño en validation



97,36 %

accuracy media

El schedule reduce la inestabilidad al final




$\eta = 0,01$
épocas 1–150

$\eta = 0,003$
épocas 151–220

$\eta = 0,001$
épocas 221–300

96 neuronas mejora consistentemente, 128 no justifica el costo adicional



+0,40 pp

96 vs 64 · 5/5 semillas

+0,20 pp

128 vs 96 · mejora no concluyente

Se elige 96 por menor costo y mayor estabilidad.

Las alternativas adicionales no aportan una mejora consistente

Se probaron

L2 con traslaciones

Rotaciones $\pm 2^\circ$, $\pm 4^\circ$, $\pm 6^\circ$

Arquitectura [784, 64, 32, 10]

Batch sizes 64 y 256

300 épocas con tasa constante

Por qué se descartaron

Empeora el Macro-F1 en 4 de 5 semillas

No producen una mejora consistente

Agregar profundidad no mejora

No muestran una ventaja clara frente a 128

Sin schedule, el modelo continúa oscilando al final

Una prueba negativa también reduce incertidumbre

Modelo final congelado

Arquitectura

[784, 96, 10]

tanh + softmax
entropía cruzada
sin L2

Entrenamiento

RMSProp, batch 128


300 épocas

η : 0,01 $\rightarrow$ 0,003 $\rightarrow$ 0,001

traslación 1 px, $p = 0,5$, sólo en training

Reentrenado desde cero sobre las 24.501 imágenes únicas

5-fold confirma estabilidad, no el objetivo de 98 %



97,86 %

accuracy out-of-fold

$\pm 0,09$ pp

desvío entre folds

El ejercicio 3 recupera 12,17 puntos de accuracy

Ejercicio 2

85,82 %

accuracy

F1 del 8

0,0000

Ejercicio 3

97,998 %


accuracy

F1 del 8

0,9644

Macro-F1: 0,8118 → 0,9797

El modelo final falla 50 de 2.497 imágenes



2.447

aciertos

50

errores

La meta de 98 % quedó a un acierto

97,998 %

accuracy obtenida

98,00 %

objetivo de CompanyX

1

acierto adicional necesario

Conclusiones

Ejercicio 1

El logístico es el TinyModel más adecuado, con umbral 0,89 y una brecha de capacidad explícita frente a BigModel.

Ejercicio 2

RMSProp-64 y Adam-128 no se separan claramente en 5-fold; el 85,82 % final se explicó sobre todo por la ausencia del 8.

Ejercicio 3

Datos completos, softmax, traslaciones, schedule y 96 neuronas llevaron la accuracy a 97,998 %, a un acierto del 98 %.

Conclusión transversal

La calidad y cobertura de los datos limitaron más que la complejidad de la red